

模糊综合评价法（FCE）建模规范

理论原理、一级与多级模型、建模步骤、结论评价与 Python 代码

适用于数学建模论文写作模板

2026 年 7 月

摘要

模糊综合评价法（Fuzzy Comprehensive Evaluation, FCE）适合处理“指标较多、评价等级带有模糊边界、既有定量数据又有专家打分”的综合评价类问题。本文按数学建模论文写法，总结模糊综合评价的完整套路：确定因素集和权重，确定评语集，从最底层开始构造隶属度矩阵，再逐级合成得到最终评价向量。文中补充模糊集合、隶属函数、与概率统计的关系、一级与多级模糊综合评价模型、结果判定原则、常见问题和 Python 代码模板。

目录

1 方法适用场景与总流程	3
2 理论原理：为什么可以使用模糊综合评价	4
2.1 模糊集合与隶属度	4
2.2 隶属函数的常见形式	4
2.3 与概率统计的关系	5
2.4 使用该方法的建模假设	6
3 一级模糊综合评价模型	6
3.1 因素集、评语集与权重向量	6
3.2 隶属度矩阵	7
3.3 模糊合成与评价向量	7
3.4 结论判定	7
4 多级模糊综合评价模型	8
4.1 为什么需要多级模型	8

目录	2
4.2 二级模糊综合评价计算	8
4.3 多级模型的论文表述模板	9
5 建模步骤规范：可直接写进论文	9
5.1 Step1: 明确评价目标与评价对象	9
5.2 Step2: 确定因素集并计算权重	9
5.3 Step3: 确定评语集	10
5.4 Step4: 逐级确定隶属度	10
5.5 Step5: 模糊合成与结论评价	10
6 指标过多时的处理：主成分分析与统计筛选	11
7 案例说明：城市生态环境质量评价	11
8 论文中的结论评价模板	12
8.1 单对象评价模板	12
8.2 多对象排序模板	12
8.3 模型优缺点评价	12
9 Python 代码模板	13
10 结果表格与图形建议	17
11 常见错误与检查清单	18
12 参考资料	18

1 方法适用场景与总流程

模糊综合评价的核心思想是：把评价对象在每个指标上的表现转化为对若干评语等级的**隶属度**，再用指标权重对隶属度进行加权合成，得到“该对象属于各评价等级的程度”。它适合回答以下问题：

- 对象能否被评价为“优、良、中、差”或“高风险、中风险、低风险”；
- 指标边界不清，例如“服务满意度高”“环境质量良好”“风险较大”；
- 既有客观数据，又有问卷、专家评分或等级投票；
- 评价对象较多，需要给出等级、排序或综合得分。

论文中可按以下五步组织：

- Step1: **解决评价类问题**。明确评价对象、评价目标和评价等级，说明该问题存在模糊性或多指标性。
- Step2: **确定因素集与权重**。构造因素集 U ；若因素过多，可分层，或先用主成分分析法、相关性分析等方法降维；每一级权重均满足非负且和为 1。
- Step3: **确定评语集**。根据问题设置 $V = \{v_1, \dots, v_m\}$ 。如果评语有评价色彩，可设为“优、良、中、差、劣”；如果无明显优劣，可设为“类型 1、类型 2、类型 3”。
- Step4: **从最后一层开始确定隶属度**。对底层指标建立隶属函数、专家频率或等级打分，得到隶属度矩阵 R ，再逐级向上合成。
- Step5: **根据隶属度确定评语并画图**。可用最大隶属度原则给等级，也可用评语赋分得到综合得分；论文中应给出层级结构图、隶属函数示意图或综合评价向量图。




图 1: 模糊综合评价建模流程图

2 理论原理：为什么可以使用模糊综合评价

2.1 模糊集合与隶属度

在经典集合中，一个元素要么属于集合，要么不属于集合，通常用 0 或 1 表示。模糊集合把这种二值判断推广为 $[0, 1]$ 上的连续取值。设论域为 X ，模糊集 $\tilde{A}$ 可写为

$$\tilde{A} = \{(x, \mu_{\tilde{A}}(x)) \mid x \in X\}, \quad \mu_{\tilde{A}}: X \rightarrow [0, 1]. \quad (1)$$

其中 $\mu_{\tilde{A}}(x)$ 称为 x 对模糊集 $\tilde{A}$ 的隶属度。 $\mu = 1$ 表示完全属于， $\mu = 0$ 表示完全不属于，中间值表示部分属于。

这正适合建模论文中的评价问题。例如“环境质量良好”没有严格边界，PM2.5、绿化率、噪声等指标对“优、良、中、差”的归属往往是逐渐变化的，而不是突然从“良”变为“中”。因此，模糊综合评价用隶属度刻画评价等级之间的过渡，能比硬分类更符合实际。

2.2 隶属函数的常见形式

隶属函数的作用是指标值 x 映射到某个评语等级的隶属度。常见形式如下。

1. 偏大型指标。 指标越大越好，例如绿化率、满意度、合格率。可取

$$\mu(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases} \quad (2)$$

2. 偏小型指标。 指标越小越好，例如污染浓度、事故率、成本。可取

$$\mu(x) = \begin{cases} 1, & x \leq a, \\ \frac{b-x}{b-a}, & a < x < b, \\ 0, & x \geq b. \end{cases} \quad (3)$$

3. 中间型或区间型指标。 指标在某一区间最好，例如温度、湿度、库存周转区间。可用三角形或梯形隶属函数：

$$\mu(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & b \leq x \leq c, \\ \frac{d-x}{d-c}, & c < x < d, \\ 0, & x \geq d. \end{cases} \quad (4)$$




图 2: 常用隶属函数示意图

2.3 与概率统计的关系

模糊综合评价与概率统计既有联系，也有区别。

1. 概念区别。 隶属度描述的是“属于某模糊概念的程度”，概率描述的是“随机事件发生的可能性”。例如“某城市空气质量属于良的隶属度为 0.7”并不等价于“该城市有 70% 的概率是良”，前者是模糊边界下的程度，后者是随机事件的概率。

2. 统计估计。 在实际建模中，隶属度可以由样本频率估计。若 N 位专家或受访者对指标 u_i 给出等级评价，其中有 n_{ij} 人选择评语 v_j ，则

$$r_{ij} = \frac{n_{ij}}{N}, \quad \sum_{j=1}^m r_{ij} = 1. \quad (5)$$

此时 r_{ij} 可解释为“群体判断下该指标对评语 v_j 的隶属程度估计”。当 N 较大且样本具有代表性时，频率型隶属度更稳定。其估计标准误可近似写为

$$SE(r_{ij}) \approx \sqrt{\frac{r_{ij}(1 - r_{ij})}{N}}. \quad (6)$$

3. 数据检验与稳健性。 建模论文中可补充以下统计处理以增强可信度：

- 对问卷数据：检查样本量、缺失值、异常值；必要时计算信度指标，如 Cronbach's alpha。
- 对专家打分：可用均值、标准差、变异系数衡量专家意见分散程度；必要时剔除明显异常评分。
- 对多个评价对象：可用 Bootstrap 对综合得分给出置信区间，或用敏感性分析检查权重变化对结论的影响。
- 对指标过多或强相关：可用相关系数矩阵、主成分分析法（PCA）或因子分析减少冗余指标。

2.4 使用该方法的建模假设

在论文“模型假设”中可写：

- H1: **评价体系完备性假设**。所选指标能够覆盖评价目标的主要影响因素，未纳入指标对最终评价影响较小。
- H2: **指标同向可比假设**。各指标经过同向化、标准化或隶属函数转化后，均可在同一评语集上比较。
- H3: **权重稳定性假设**。指标权重反映评价期内相对重要程度，且每一级权重非负、和为1。
- H4: **隶属函数合理性假设**。隶属函数或专家等级频率能够较好反映指标与评语等级之间的关系。
- H5: **加权合成假设**。指标之间的综合影响可用加权平均或其他模糊算子近似表达；若存在严重交互作用，应在模型局限中说明。

3 一级模糊综合评价模型

3.1 因素集、评语集与权重向量

设评价指标集合为

$$U = \{u_1, u_2, \dots, u_n\}, \quad (7)$$

评语集合为

$$V = \{v_1, v_2, \dots, v_m\}. \quad (8)$$

若评语有顺序,可取 $V = \{\text{优}, \text{良}, \text{中}, \text{差}, \text{劣}\}$;若只是分类,则可取 $V = \{\text{类型 A}, \text{类型 B}, \text{类型 C}\}$ 。

权重向量为

$$W = (w_1, w_2, \dots, w_n), \quad w_i \geq 0, \quad \sum_{i=1}^n w_i = 1. \quad (9)$$

权重可由 AHP、熵权法、专家赋权、PCA 或组合赋权确定。若用 AHP，应另外给出判断矩阵和一致性检验；若用熵权或 PCA，应说明数据标准化和方差贡献率。

3.2 隶属度矩阵

对每个因素 u_i , 计算其对每个评语 v_j 的隶属度 r_{ij} , 构成模糊关系矩阵

$$R = (r_{ij})_{n \times m} = \begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \cdots & r_{nm} \end{pmatrix}. \quad (10)$$

若 R 来源于专家投票频率, 每行通常满足 $\sum_j r_{ij} = 1$; 若来源于多个重叠隶属函数, 每行不一定天然为 1, 可根据论文需要进行归一化。

3.3 模糊合成与评价向量

一级模糊综合评价的基本形式为

$$B = W \circ R = (b_1, b_2, \dots, b_m). \quad (11)$$

最常用的是加权平均型算子:

$$b_j = \sum_{i=1}^n w_i r_{ij}, \quad j = 1, 2, \dots, m. \quad (12)$$

也可使用最大-最小型算子:

$$b_j = \max_i \{\min(w_i, r_{ij})\}, \quad (13)$$

但建模竞赛和评价论文中通常优先采用加权平均型, 因为它更充分利用全部指标信息, 结果也便于解释。

3.4 结论判定

设 $B = (b_1, \dots, b_m)$ 。常见判定方法如下:

1. **最大隶属度原则:** 若 $b_k = \max_j b_j$, 则综合评价等级为 v_k 。
2. **综合得分法:** 若评语有顺序, 给评语赋分 $Q = (q_1, \dots, q_m)$, 则

$$S = BQ^T = \sum_{j=1}^m b_j q_j. \quad (14)$$

得分 S 可用于多个对象排序。

3. **归一化解释:** 若 $\sum_j b_j \neq 1$, 可先令 $\hat{b}_j = b_j / \sum_j b_j$, 再进行等级判断或计算得分。

4 多级模糊综合评价模型

4.1 为什么需要多级模型

当指标很多时, 直接把所有指标放在同一层会产生两个问题: 一是权重过分分散, 二是评价矩阵过大、解释性下降。此时应把因素集分解为若干子因素集:

$$U = \{U_1, U_2, \dots, U_s\}, \quad U_i = \{u_{i1}, u_{i2}, \dots, u_{in_i}\}. \quad (15)$$

每个子因素集内部先进行一次模糊综合评价, 再把各子系统评价结果作为上一层的隶属度矩阵继续合成。




图 3: 多级模糊综合评价结构图模板

4.2 二级模糊综合评价计算

对第 i 个一级因素 U_i , 设其内部权重为

$$W_i = (w_{i1}, w_{i2}, \dots, w_{in_i}), \quad \sum_{k=1}^{n_i} w_{ik} = 1, \quad (16)$$

隶属度矩阵为

$$R_i = (r_{ikj})_{n_i \times m}. \quad (17)$$

则第 i 个一级因素的评价向量为

$$B_i = W_i R_i = (b_{i1}, b_{i2}, \dots, b_{im}). \quad (18)$$

把所有 B_i 按行组成上一层的隶属度矩阵:

$$R^{(2)} = \begin{pmatrix} B_1 \\ B_2 \\ \vdots \\ B_s \end{pmatrix}_{s \times m}. \quad (19)$$

设一级因素权重为

$$A = (a_1, a_2, \dots, a_s), \quad \sum_{i=1}^s a_i = 1, \quad (20)$$

则最终评价向量为

$$B = AR^{(2)}. \quad (21)$$

4.3 多级模型的论文表述模板

可直接写为：

由于评价对象受多个层级因素共同影响，且各指标对评价等级的归属具有模糊性，本文采用多级模糊综合评价法。首先将因素集 U 分解为若干一级因素 U_i ，并在每个一级因素下设置二级指标；其次，依据专家评分、客观数据或隶属函数构造底层隶属度矩阵 R_i ；再次，利用各级权重向量 W_i 逐层进行模糊合成；最后依据最大隶属度原则和综合得分法确定评价等级与排序。该方法能够保留各评价等级的隶属信息，适用于边界不清、定性与定量指标并存的综合评价问题。

5 建模步骤规范：可直接写进论文

5.1 Step1：明确评价目标与评价对象

写清楚评价目标 G 、评价对象 A_l 、评价期和数据来源。若只有一个对象，结论是等级评价；若有多个对象，结论是排序或等级比较。

示例写法：本文以某对象的综合质量为评价目标，构建由若干一级指标和二级指标组成的评价体系。由于评价等级之间存在模糊边界，且指标既包括客观数据又包括专家打分，故采用模糊综合评价法进行建模。

5.2 Step2：确定因素集并计算权重

因素集可写为

$$U = \{u_1, u_2, \dots, u_n\}. \quad (22)$$

多级情形写为

$$U = \{U_1, U_2, \dots, U_s\}, \quad U_i = \{u_{i1}, \dots, u_{in_i}\}. \quad (23)$$

权重计算要满足：

$$w_i \geq 0, \quad \sum_i w_i = 1. \quad (24)$$

权重来源可以是：专家赋权、AHP、熵权法、变异系数法、PCA 或组合赋权。若指标数量过多且相关性强，可先计算相关系数矩阵，删除高度重复指标，或用 PCA 提取主成分。

5.3 Step3：确定评语集

有评价色彩的评语集：

$$V = \{\text{优, 良, 中, 差, 劣}\}. \quad (25)$$

可对应分值

$$Q = (100, 80, 60, 40, 20) \quad (26)$$

或

$$Q = (5, 4, 3, 2, 1). \quad (27)$$

无评价色彩的评语集：

$$V = \{\text{稳定型, 波动型, 风险型}\}. \quad (28)$$

这种情况下不宜随意赋分，通常只用最大隶属度或类别解释。

5.4 Step4：逐级确定隶属度

底层隶属度可由三种方式得到。

1. 专家投票频率法。 若 N 位专家对指标 u_i 给出评语，选择 v_j 的人数为 n_{ij} ，则

$$r_{ij} = \frac{n_{ij}}{N}. \quad (29)$$

2. 隶属函数法。 若有客观指标值 x_i ，先确定指标类型和等级阈值，再用隶属函数得到 r_{ij} 。

3. 问卷量表法。 若问卷选项本身就是评语等级，统计每个指标在各等级上的比例；若问卷是 1-5 分，可将分数区间映射到评语集。

5.5 Step5：模糊合成与结论评价

单层模型：

$$B = WR. \quad (30)$$

多层模型：

$$B_i = W_i R_i, \text{quad} R^{(2)} = (B_1, B_2, \dots, B_s)^T, \quad B = AR^{(2)}. \quad (31)$$

最终给出：

- 综合评价向量 B ；
- 最大隶属度对应的评价等级；

- 若评语有顺序，给出综合得分 $S = BQ^T$ ；
- 若有多个对象，给出排序表和敏感性分析。

6 指标过多时的处理：主成分分析与统计筛选

如果指标数量过多，直接建立模糊综合评价模型会导致权重过小、矩阵复杂、解释困难。可采用以下处理：

1. **相关性筛选**：若两个指标相关系数绝对值很高，可保留更有解释性的一个。
2. **PCA 降维**：对标准化后的指标矩阵 X 求协方差矩阵或相关矩阵的特征值与特征向量。第 k 个主成分可写为

$$F_k = l_{k1}X_1 + l_{k2}X_2 + \cdots + l_{kp}X_p. \quad (32)$$

选择累计方差贡献率达到 80% 或 85% 的前若干主成分，作为新因素或作为构造客观权重的依据。

3. **专家合并**：将含义相近的指标合并为一个二级指标，保持论文解释性。

注意：PCA 得到的是数据驱动的线性组合，解释性可能弱于原始指标。因此建模论文中建议写成“用于辅助筛选和降维”，而不是完全替代专业指标体系。

7 案例说明：城市生态环境质量评价

赵鑫等在城市生态环境质量评价中，将评价体系划分为自然环境、社会方面、经济方面、政策方面 4 个一级指标，并设置 21 个二级指标；文中先由 AHP 得到各级权重，再用模糊综合评价进行综合评价。其评语集采用五等级：优、良、中等、差、极差，对应区间分别为 $(0.8, 1.0]$ 、 $(0.6, 0.8]$ 、 $(0.4, 0.6]$ 、 $(0.2, 0.4]$ 、 $[0, 0.2]$ 。

以自然环境为例，其二级指标权重为

$$W_1 = (0.221, 0.170, 0.203, 0.238, 0.168), \quad (33)$$

对应隶属度矩阵为

$$R_1 = \begin{pmatrix} 0.76 & 0.56 & 0.63 & 0.55 & 0.64 \\ 0.53 & 0.73 & 0.79 & 0.45 & 0.65 \\ 0.62 & 0.43 & 0.45 & 0.35 & 0.84 \\ 0.64 & 0.44 & 0.32 & 0.45 & 0.32 \\ 0.44 & 0.42 & 0.34 & 0.23 & 0.41 \end{pmatrix}. \quad (34)$$

于是

$$B_1 = W_1 R_1 = (0.6102, 0.5104, 0.4982, 0.4148, 0.5675). \quad (35)$$

同理可得其他一级指标的评价向量：

$$B_2 = (0.6203, 0.6246, 0.6469, 0.6603, 0.6390), \quad (36)$$

$$B_3 = (0.6249, 0.4688, 0.5044, 0.6279, 0.5564), \quad (37)$$

$$B_4 = (0.4867, 0.4699, 0.6166, 0.4035, 0.6035). \quad (38)$$

若一级权重为 $A = (0.316, 0.342, 0.191, 0.151)$ ，则最终评价向量约为

$$B = (0.5978, 0.5354, 0.5681, 0.5378, 0.5953). \quad (39)$$

根据最大隶属度原则，第一等级分量最大；若再结合等级区间或实际论文的评价规则，可进一步给出“中等”或相应等级解释。实际写作时，应说明采用的是“最大隶属度判别”还是“综合得分区间判别”，避免结论口径不一致。

8 论文中的结论评价模板

8.1 单对象评价模板

由计算可得综合评价向量

$$B = (b_1, b_2, \dots, b_m). \quad (40)$$

其中 b_k 最大，说明评价对象对评语 v_k 的隶属程度最高。若采用最大隶属度原则，则该对象综合等级为 v_k 。若评语集为有序等级，并赋予分值 Q ，则综合得分为 $S = BQ^T$ ，该得分位于 $[q_{k+1}, q_k]$ 区间内，说明对象整体处于相邻等级之间，偏向 v_k 。结合各一级指标评价向量可知，影响最终评价的主要短板为 $\dots$ ，优势指标为 $\dots$ 。

8.2 多对象排序模板

对每个评价对象 A_l 分别计算综合评价向量 B_l 和得分 S_l 。根据 S_l 由高到低排序可得

$$A_{(1)} \succ A_{(2)} \succ \dots \succ A_{(m)}. \quad (41)$$

若相邻对象得分差距较小，应进一步进行权重敏感性分析或 Bootstrap 置信区间比较；若排序在合理扰动下保持不变，则说明结论较稳健。

8.3 模型优缺点评价

优点：能处理模糊等级边界；能融合定量数据和定性判断；结果以隶属度向量呈现，解释性较强；适合多指标综合评价。

局限：隶属函数和权重具有一定主观性；若指标高度相关，可能重复计权；最大隶属度原则可能忽略次高等级信息；当样本量较小或专家意见分散时，隶属度稳定性不足。

改进：可结合 AHP、熵权法、PCA、灰色关联、TOPSIS 或 Bootstrap 敏感性分析，提高权重确定和结论检验的可靠性。

9 Python 代码模板

以下代码覆盖单层模糊综合评价、多级模糊综合评价、专家投票构造隶属度矩阵、PCA 辅助权重、Bootstrap 稳健性检验和柱状图绘制。

```
import numpy as np
import pandas as pd

def normalize_weights(w):
    """Return a non-negative weight vector whose sum is 1."""
    w = np.asarray(w, dtype=float)
    if np.any(w < 0):
        raise ValueError("Weights must be non-negative.")
    s = w.sum()
    if s <= 0:
        raise ValueError("The sum of weights must be positive.")
    return w / s

def normalize_rows(R):
    """Normalize each row of a membership matrix."""
    R = np.asarray(R, dtype=float)
    if np.any(R < 0):
        raise ValueError("Membership degrees must be non-negative.")
    row_sums = R.sum(axis=1, keepdims=True)
    if np.any(row_sums <= 0):
        raise ValueError("Every row must have positive sum.")
    return R / row_sums

def fce_single_level(weights, R, scores=None, labels=None, normalize_R=False):
    """
    Single-level fuzzy comprehensive evaluation.
    weights: length n
    R: n by m membership matrix
    scores: optional length m score vector for remarks
    labels: optional length m remark labels
    """
```

```

"""
W = normalize_weights(weights)
R = np.asarray(R, dtype=float)
if normalize_R:
    R = normalize_rows(R)
if R.shape[0] != len(W):
    raise ValueError("R rows must match the number of weights.")

B = W @ R
if B.sum() > 0:
    B_norm = B / B.sum()
else:
    B_norm = B

k = int(np.argmax(B))
result = {
    "B": B,
    "B_normalized": B_norm,
    "max_index": k,
    "label": labels[k] if labels is not None else k
}
if scores is not None:
    scores = np.asarray(scores, dtype=float)
    if len(scores) != R.shape[1]:
        raise ValueError("scores must match the number of remarks.")
    result["score"] = float(B_norm @ scores)
return result

def fce_multilevel(top_weights, sub_weights, sub_Rs,
                   scores=None, labels=None, normalize_R=False):
    """
    Two-level fuzzy comprehensive evaluation.
    top_weights: weights of first-level factors, length s
    sub_weights: list of second-level weight vectors
    sub_Rs: list of second-level membership matrices
    """
    if len(sub_weights) != len(sub_Rs):
        raise ValueError("sub_weights and sub_Rs must have the same length.")

    first_level_vectors = []
    for w_i, R_i in zip(sub_weights, sub_Rs):
        res_i = fce_single_level(w_i, R_i, normalize_R=normalize_R)
        first_level_vectors.append(res_i["B"])

```

```

R_top = np.vstack(first_level_vectors)
final = fce_single_level(top_weights, R_top, scores=scores, labels=labels)
final["first_level_vectors"] = R_top
return final

def membership_from_expert_votes(vote_counts):
    """
    Convert expert vote counts to a membership matrix.
    vote_counts[i, j] is the number of experts selecting remark j for factor i.
    """
    return normalize_rows(vote_counts)

def benefit_membership(x, a, b):
    """Membership of a benefit-type indicator to a good grade."""
    x = np.asarray(x, dtype=float)
    return np.clip((x - a) / (b - a), 0, 1)

def cost_membership(x, a, b):
    """Membership of a cost-type indicator to a good grade."""
    x = np.asarray(x, dtype=float)
    return np.clip((b - x) / (b - a), 0, 1)

def trapezoid_membership(x, a, b, c, d):
    """Trapezoidal membership function."""
    x = np.asarray(x, dtype=float)
    y = np.zeros_like(x, dtype=float)
    y = np.where((a < x) & (x < b), (x - a) / (b - a), y)
    y = np.where((b <= x) & (x <= c), 1.0, y)
    y = np.where((c < x) & (x < d), (d - x) / (d - c), y)
    return np.clip(y, 0, 1)

def pca_objective_weights(X, n_components=None):
    """
    PCA-assisted objective weights.
    X: samples by indicators data matrix.
    Requires scikit-learn. Use as an auxiliary method, not a black-box substitute.
    """
    from sklearn.preprocessing import StandardScaler

```

```

from sklearn.decomposition import PCA

X_std = StandardScaler().fit_transform(np.asarray(X, dtype=float))
pca = PCA(n_components=n_components)
pca.fit(X_std)
loadings = np.abs(pca.components_).T
contrib = pca.explained_variance_ratio_
raw = loadings @ contrib
return normalize_weights(raw), contrib

def bootstrap_score_ci(counts, weights, scores, n_boot=2000, seed=0):
    """
    Bootstrap confidence interval for FCE score based on expert vote counts.
    counts: n by m vote count matrix.
    """
    rng = np.random.default_rng(seed)
    counts = np.asarray(counts, dtype=int)
    n_factors, n_grades = counts.shape
    boot_scores = []
    for _ in range(n_boot):
        boot_counts = np.zeros_like(counts)
        for i in range(n_factors):
            probs = counts[i] / counts[i].sum()
            sample = rng.multinomial(counts[i].sum(), probs)
            boot_counts[i] = sample
        Rb = membership_from_expert_votes(boot_counts)
        res = fce_single_level(weights, Rb, scores=scores)
        boot_scores.append(res["score"])
    return np.percentile(boot_scores, [2.5, 50, 97.5])

if __name__ == "__main__":
    labels = ["excellent", "good", "medium", "poor", "very poor"]
    scores = [100, 80, 60, 40, 20]

    # Example: natural environment in the urban ecological environment case.
    W1 = [0.221, 0.170, 0.203, 0.238, 0.168]
    R1 = [
        [0.76, 0.56, 0.63, 0.55, 0.64],
        [0.53, 0.73, 0.79, 0.45, 0.65],
        [0.62, 0.43, 0.45, 0.35, 0.84],
        [0.64, 0.44, 0.32, 0.45, 0.32],
        [0.44, 0.42, 0.34, 0.23, 0.41],
    ]

```



```

]
res = fce_single_level(W1, R1, scores=scores, labels=labels)
print("Natural environment B:", np.round(res["B"], 4))
print("Max-membership label:", res["label"])
print("Score:", round(res["score"], 2))

# Two-level example using four first-level factors.
top_weights = [0.316, 0.342, 0.191, 0.151]
W2 = [0.066, 0.207, 0.155, 0.111, 0.071, 0.111, 0.111, 0.168]
R2 = [
    [0.36, 0.56, 0.36, 0.64, 0.54],
    [0.54, 0.63, 0.54, 0.73, 0.45],
    [0.55, 0.53, 0.56, 0.53, 0.62],
    [0.54, 0.74, 0.73, 0.52, 0.43],
    [0.52, 0.34, 0.74, 0.63, 0.83],
    [0.56, 0.64, 0.62, 0.83, 0.82],
    [0.91, 0.45, 0.76, 0.73, 0.83],
    [0.83, 0.88, 0.82, 0.65, 0.74],
]
W3 = [0.146, 0.141, 0.312, 0.110, 0.120, 0.170]
R3 = [
    [0.65, 0.43, 0.65, 0.33, 0.76],
    [0.94, 0.43, 0.64, 0.34, 0.64],
    [0.54, 0.44, 0.37, 0.76, 0.43],
    [0.54, 0.37, 0.43, 0.64, 0.62],
    [0.62, 0.63, 0.78, 0.58, 0.82],
    [0.56, 0.54, 0.37, 0.91, 0.32],
]
W4 = [0.667, 0.333]
R4 = [
    [0.55, 0.34, 0.51, 0.52, 0.72],
    [0.36, 0.73, 0.83, 0.17, 0.37],
]
final = fce_multilevel(top_weights, [W1, W2, W3, W4], [R1, R2, R3, R4],
                      scores=scores, labels=labels)
print("First-level vectors:\n", np.round(final["first_level_vectors"], 4))
print("Final B:", np.round(final["B"], 4))
print("Final score:", round(final["score"], 2))

```

10 结果表格与图形建议

论文中至少给出以下表格和图形：

- 1. **评价指标体系图**：展示目标层、一级因素、二级因素。
- 2. **权重表**：每一级权重之和必须为 1；多级模型需列出局部权重和综合权重。
- 3. **隶属度矩阵表**：每个因素对各评语等级的隶属度。
- 4. **综合评价向量表**：给出 B 、最大隶属度等级、综合得分。
- 5. **柱状图或雷达图**：展示最终评价向量或一级指标得分，便于论文解释。

11 常见错误与检查清单

表 1: 模糊综合评价建模检查清单

检查项	常见错误	正确做法
因素集	指标混乱，一级二级不分	先画层级结构图, 明确每个指标所属层级
权重	权重和不等于 1	每一级单独归一化, 局部权重与综合权重要分清
评语集	评语无顺序却强行赋分	有序评语才适合综合得分, 无序类别只做隶属度判别
隶属度	把原始数据直接当隶属度	先用频率、标准化或隶属函数映射到 $[0, 1]$
矩阵维度	W 与 R 维度不匹配	W 长度等于 R 的行数, R 列数等于评语数
多级评价	直接把所有指标一次性合成	先算底层 B_i , 再把 B_i 组成上一层矩阵
结论	只说“最大值为某等级”不解释	同时解释主要优势、短板、敏感性和实际含义

12 参考资料

1. Zadeh, L. A. Fuzzy Sets. *Information and Control*, 1965, 8(3): 338–353. ScienceDirect
摘要说明，模糊集由取值在 0 到 1 之间的隶属函数刻画。

2. Xu, X.; Wang, J. A fuzzy comprehensive evaluation method based on the joint distribution dynamic membership degree for classification problems. *Journal of Intelligent*

of Fuzzy Systems, 2024. 该文将 FCE 表示为 $B = W \circ R$, 并说明其由因素、评语、模糊关系矩阵和权重向量组成。

3. SPSSAU 帮助文档: 模糊综合评价。该文档给出指标项、评语、权重向量和判断矩阵的通俗解释, 并总结了“确定评价指标和评语集、构造权重向量和矩阵、计算并决策评价”的操作流程。
4. 赵鑫, 孙春花, 沈贤. 基于层次分析法的城市生态环境质量评价. 中国资源综合利用, 2022, 40(5): 163–166. 该案例将 AHP 与模糊综合评价结合, 用于城市生态环境质量评价。
5. Gewers, F. L. et al. Principal Component Analysis: A Natural Approach to Data Exploration. arXiv:1804.02502, 2018. 可作为 PCA 辅助降维的参考。