

时间序列常见建模理论与方法

经济学与数学建模示范案例

适用于数学建模、经济预测、课程复习与论文写作

2026 年 7 月

摘要

时间序列是按时间顺序观测得到的数据，常见于 GDP、CPI、股票价格、销售额、气温、客流量、发电量等问题。与普通横截面数据不同，时间序列的核心特征是“顺序不能打乱”，并且当前值往往与过去值相关。本讲义从建模角度介绍时间序列的常见理论与方法，包括趋势模型、分解模型、移动平均、指数平滑、平稳性、ACF/PACF、AR、MA、ARMA、ARIMA、SARIMA、动态回归、VAR、机器学习预测、误差评价与论文写作模板。最后给出一个“月度销售额预测”的完整示范案例，包含公式、建模步骤、Python 代码、图像和评价指标。

目录

1	时间序列建模的基本思想	2
1.1	什么是时间序列	2
1.2	常见建模问题	2
1.3	时间序列的基本组成	3
2	数据预处理与探索性分析	3
2.1	数据频率与时间索引	3
2.2	缺失值与异常值	4
2.3	训练集与测试集划分	4
3	时间序列分解模型	5
3.1	加法分解	5
3.2	乘法分解	5
3.3	适用条件与建模步骤	6
4	基础预测方法	6
4.1	平均法	6
4.2	朴素法	7
4.3	季节朴素法	7
4.4	移动平均	7
4.5	Python 示例	7

5 指数平滑模型	8
5.1 一次指数平滑	8
5.2 Holt 线性趋势模型	8
5.3 Holt-Winters 季节模型	8
5.4 适用条件	9
6 平稳性、自相关与差分	9
6.1 平稳性的直观含义	9
6.2 差分	9
6.3 自相关函数 ACF	10
6.4 偏自相关函数 PACF	10
6.5 白噪声	11
7 AR、MA、ARMA 与 ARIMA 模型	11
7.1 AR 自回归模型	11
7.2 MA 移动平均模型	11
7.3 ARMA 模型	11
7.4 ARIMA 模型	12
7.5 ARIMA 建模步骤	12
8 SARIMA 季节 ARIMA 模型	12
8.1 模型形式	12
8.2 参数含义	13
9 动态回归、ARIMAX 与外生变量	13
9.1 普通趋势回归	13
9.2 带外生变量的时间序列模型	13
10 VAR 模型与多变量时间序列	14
10.1 VAR 的思想	14
10.2 适用场景	14
10.3 Python 示例	14
11 机器学习时间序列预测	15
11.1 基本思想	15
11.2 常见方法	15
11.3 滞后特征代码	15
12 预测评价指标与残差诊断	15
12.1 常见误差指标	15
12.2 残差诊断	16

13 示范案例：月度销售额预测	17
13.1 问题描述	17
13.2 建模假设	17
13.3 候选模型	18
13.4 评价结果	18
13.5 完整 Python 代码	18
13.6 规范论文写法示例	20
14 不同方法的选择建议	20
15 常见错误与注意事项	21
16 总结	21
参考资料	22

1 时间序列建模的基本思想

1.1 什么是时间序列

时间序列可以写成

$$\{y_t\}, \quad t = 1, 2, \dots, n,$$

其中 t 表示时间点, y_t 表示第 t 期的观测值。例如月度销售额、季度 GDP、每日股票收盘价、小时级气温等。时间序列建模的目标通常不是解释单个样本, 而是研究

过去的变化规律 $\implies$ 现在的结构 $\implies$ 未来的预测.

在经济学中, 常见变量包括

$$GDP_t, \quad CPI_t, \quad P_t, \quad r_t, \quad Y_t,$$


分别表示第 t 期的国内生产总值、物价指数、价格、利率和收入等。数学和统计中则更强调随机过程、平稳性、自相关函数和预测误差。

建模提醒: 时间序列不能像普通样本那样随机打乱训练集和测试集。预测必须遵守时间顺序, 即只能用过去的数据预测未来的数据。

1.2 常见建模问题

时间序列建模中常见的任务有:

1. **描述:** 画图观察趋势、周期、季节性、突变点和异常值。
2. **解释:** 分析影响变量变化的主要因素, 例如价格、政策、节假日和天气。
3. **预测:** 根据历史数据预测未来 h 期。
4. **控制:** 根据预测结果制定库存、生产、预算、调度等决策。



建模核心：数据按时间相关，不能随机打乱；预测必须用过去推未来。

图 1: 时间序列建模的一般流程

1.3 时间序列的基本组成

许多时间序列可以分解为趋势项、季节项、周期项和随机项：

$$y_t = T_t + S_t + C_t + \varepsilon_t.$$

其中 T_t 为长期趋势， S_t 为季节性， C_t 为较长周期波动， ε_t 为随机扰动。如果波动幅度随水平增大而增大，常采用乘法分解：

$$y_t = T_t \times S_t \times C_t \times \varepsilon_t.$$

组成	含义	例子
趋势 T_t	长期上升或下降方向	GDP 长期增长、人口增长、销售额长期提高
季节 S_t	固定周期内重复出现的模式	月度销售有春节或暑假效应, 用电量有工作日效应
周期 C_t	不严格固定周期的长期波动	经济繁荣、衰退、复苏
随机项 ε_t	无法完全解释的扰动	突发事件、测量误差、市场情绪

2 数据预处理与探索性分析

2.1 数据频率与时间索引

建模前首先要确认时间频率：年、季度、月、周、日、小时或分钟。频率决定季节周期，例如月度数据通常取 $m = 12$ ，季度数据取 $m = 4$ ，周度数据可能取 $m = 52$ 。




图 2: 示例：某地区月度销售额时间序列

2.2 缺失值与异常值

时间序列常见数据问题包括缺失、重复、时间不连续、异常峰值和结构突变。处理原则如下：

- 少量缺失可用线性插值、前向填充或同季节均值填补；
- 大量缺失不宜盲目填补，应说明数据不足；
- 异常值不能简单删除，要判断是录入错误还是突发事件；
- 重大政策变化、疫情、战争等可能导致结构突变，应分阶段建模。

2.3 训练集与测试集划分

时间序列常用“前面一段训练、后面一段测试”：

$$\underbrace{y_1, \dots, y_T}_{\text{训练集}} \implies \underbrace{y_{T+1}, \dots, y_{T+h}}_{\text{测试集}}$$

更稳妥的做法是滚动预测验证，也叫 rolling forecasting origin。




图 3: 滚动预测验证示意图

3 时间序列分解模型

3.1 加法分解

加法分解适用于季节波动幅度大致稳定的情况：

$$y_t = T_t + S_t + R_t.$$

其中 R_t 表示残差项。建模时可以先估计趋势，再估计季节效应，最后分析残差是否接近白噪声。

3.2 乘法分解

乘法分解适用于序列水平越高、季节波动越大的情况：

$$y_t = T_t \cdot S_t \cdot R_t.$$

例如某商品销量从每月 1000 件增长到每月 10000 件，季节旺季增幅也从几十件变成几千件，此时乘法模型更合理。常见处理是取对数：

$$\log y_t = \log T_t + \log S_t + \log R_t.$$

这样可以把乘法结构转成加法结构。




图 4: 示例时间序列的趋势、季节和随机项分解

3.3 适用条件与建模步骤

1. 画原始序列图，判断是否存在趋势和季节性；
2. 判断季节波动幅度是否随水平增大；
3. 若幅度稳定，采用加法分解；若幅度随水平增大，采用乘法分解或对数变换；
4. 分解后检查残差是否还有明显结构；
5. 若残差仍有自相关，需要继续建立 ARIMA 或其他模型。

4 基础预测方法

4.1 平均法

平均法认为未来等于历史均值：

$$\hat{y}_{T+h} = \bar{y} = \frac{1}{T} \sum_{t=1}^T y_t.$$

它适用于没有明显趋势和季节性的平稳序列，可以作为基准模型。

4.2 朴素法

朴素法认为下一期等于最近一期：

$$\hat{y}_{T+h} = y_T.$$

金融价格、随机游走类问题中，朴素法往往是一个很强的基准。

4.3 季节朴素法

对于周期为 m 的季节序列，季节朴素法认为未来同一季节接近上一年同季节：

$$\hat{y}_{T+h} = y_{T+h-m}.$$

例如预测今年 12 月销售额，可以参考去年 12 月销售额。

4.4 移动平均

k 期移动平均为

$$MA_t = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}.$$

移动平均的作用是平滑短期波动，突出长期趋势。




图 5: 移动平均平滑短期波动

4.5 Python 示例

```
1 import pandas as pd
2
3 # y 是带时间索引的 pandas Series
4 ma3 = y.rolling(window=3).mean()
5 ma12 = y.rolling(window=12).mean()
```

```

6
7 # 季节朴素预测：用上一年同月份预测下一年同月份
8 forecast = y.iloc[-12:].copy()
9 forecast.index = pd.date_range(y.index[-1] + pd.offsets.MonthBegin(1), periods=12, freq='
  MS')

```

5 指数平滑模型

5.1 一次指数平滑

一次指数平滑适用于没有明显趋势和季节性的序列：

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t, \quad 0 < \alpha < 1.$$

其中 α 越大，越重视最近数据； α 越小，预测越平滑。

5.2 Holt 线性趋势模型

当数据有趋势但无明显季节性时，可使用 Holt 模型：

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1},$$

$$\hat{y}_{t+h} = \ell_t + hb_t.$$

这里 ℓ_t 是水平项， b_t 是趋势项。

5.3 Holt-Winters 季节模型

当数据同时有趋势和季节性时，可使用 Holt-Winters 模型。加法季节模型可写成

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1},$$

$$s_t = \gamma(y_t - \ell_t) + (1 - \gamma)s_{t-m},$$

$$\hat{y}_{t+h} = \ell_t + hb_t + s_{t+h-m}.$$

其中 m 是季节周期。statsmodels 的 ExponentialSmoothing 提供了 Holt-Winters 指数平滑实现，支持拟合和预测。

5.4 适用条件

模型	适用情况	不适合情况
一次指数平滑	无明显趋势、无明显季节	有明显上升下降趋势
Holt 模型	有趋势、无明显季节	强季节波动
Holt-Winters	有趋势且有季节性	结构突变严重、季节周期变化

```
1 from statsmodels.tsa.holtwinters import ExponentialSmoothing
2
3 model = ExponentialSmoothing(
4     train,
5     trend='add',
6     seasonal='add',
7     seasonal_periods=12
8 )
9 fit = model.fit(optimized=True)
10 forecast = fit.forecast(12)
```

6 平稳性、自相关与差分

6.1 平稳性的直观含义

平稳序列大致要求均值、方差和自相关结构不随时间明显变化。直观上，序列围绕固定水平上下波动，没有长期趋势，也没有越来越大的波动。

弱平稳通常要求：

$$\begin{aligned} E(y_t) &= \mu, \\ \text{Var}(y_t) &= \sigma^2, \\ \text{Cov}(y_t, y_{t-k}) &= \gamma_k, \end{aligned}$$

其中 γ_k 只与滞后阶数 k 有关，与具体时刻 t 无关。

6.2 差分

若序列有趋势，可以作一阶差分：

$$\nabla y_t = y_t - y_{t-1}.$$

若序列有季节性，可以作季节差分：

$$\nabla_m y_t = y_t - y_{t-m}.$$

差分的目的不是“让图好看”，而是把非平稳的水平值转化为较平稳的变化量。




图 6: 一阶差分与季节差分的直观效果

6.3 自相关函数 ACF

自相关函数描述 y_t 与 y_{t-k} 的相关程度：

$$\rho_k = \frac{Cov(y_t, y_{t-k})}{Var(y_t)}.$$

ACF 可用于判断序列是否存在记忆性、季节性和 MA 阶数。

6.4 偏自相关函数 PACF

PACF 衡量在剔除中间滞后影响后， y_t 与 y_{t-k} 的直接相关程度。PACF 常用于判断 AR 阶数。




图 7: ACF 与 PACF 可用于辅助选择 ARIMA 阶数

6.5 白噪声

若残差 e_t 没有明显自相关，均值接近 0，方差相对稳定，则可以认为模型已经较好地提取了序列中的信息。若残差仍有明显趋势、季节性或自相关，说明模型还有改进空间。

7 AR、MA、ARMA 与 ARIMA 模型

7.1 AR 自回归模型

AR(p) 模型写成

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t.$$

意思是当前值由过去 p 期值线性决定。适合具有惯性和延续性的平稳序列。

7.2 MA 移动平均模型

MA(q) 模型写成

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

意思是当前值受当前冲击和过去预测误差影响。

7.3 ARMA 模型

ARMA(p, q) 结合 AR 和 MA:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

它适用于平稳序列。

7.4 ARIMA 模型

若原序列非平稳，但经过 d 次差分后平稳，则可用 $ARIMA(p, d, q)$ ：

$$\phi(B)(1-B)^d y_t = c + \theta(B)\varepsilon_t.$$

其中 B 是滞后算子， $By_t = y_{t-1}$ 。statsmodels 文档中，ARIMA 是 ARIMA 型模型的基本接口，既包括 AR、MA、ARMA、ARIMA，也包括 SARIMA 和带外生变量的回归误差模型。

7.5 ARIMA 建模步骤

1. 画图观察趋势、季节性、异常值；
2. 通过差分使序列尽量平稳；
3. 用 ACF/PACF 初步判断 p, q ；
4. 试验多个模型，用 AIC/BIC、残差诊断、测试误差综合选择；
5. 用模型预测未来，并给出置信区间或预测区间；
6. 评价 MAE、RMSE、MAPE 等误差指标。

```

1 from statsmodels.tsa.arima.model import ARIMA
2
3 # order=(p,d,q)
4 model = ARIMA(train, order=(1,1,1))
5 fit = model.fit()
6 forecast = fit.forecast(steps=12)
7 print(fit.summary())

```

8 SARIMA 季节 ARIMA 模型

8.1 模型形式

若序列有明显季节周期，可使用 SARIMA：

$$SARIMA(p, d, q)(P, D, Q)_m.$$

其中 (p, d, q) 是非季节部分， (P, D, Q) 是季节部分， m 是季节周期。完整形式可写为

$$\Phi(B^m)\phi(B)(1-B)^d(1-B^m)^D y_t = \Theta(B^m)\theta(B)\varepsilon_t.$$

8.2 参数含义

参数	含义
p	非季节自回归阶数，表示受最近多少期水平影响
d	非季节差分次数，用来消除普通趋势
q	非季节移动平均阶数，表示受过去误差影响的阶数
P	季节自回归阶数，例如受去年同月影响
D	季节差分次数，例如 $y_t - y_{t-12}$
Q	季节移动平均阶数
m	季节周期，月度数据常取 12，季度数据常取 4

```

1 from statsmodels.tsa.statespace.sarimax import SARIMAX
2
3 model = SARIMAX(
4     train,
5     order=(1,1,1),
6     seasonal_order=(1,1,1,12),
7     enforce_stationarity=False,
8     enforce_invertibility=False
9 )
10 fit = model.fit(dispatch=False)
11 forecast = fit.forecast(12)

```

9 动态回归、ARIMAX 与外生变量

9.1 普通趋势回归

若变量随时间近似线性变化，可先建立趋势回归：

$$y_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

如果存在季节性，可以加入季节虚拟变量：

$$y_t = \beta_0 + \beta_1 t + \sum_{j=1}^{m-1} \delta_j D_{j,t} + \varepsilon_t.$$

9.2 带外生变量的时间序列模型

经济问题中，目标变量往往受其他变量影响。例如销售额受价格、广告、节假日、温度影响：

$$y_t = \beta_0 + \beta_1 price_t + \beta_2 ad_t + \beta_3 holiday_t + u_t.$$

如果误差 u_t 存在自相关，可以令 u_t 服从 ARIMA 模型，这就是动态回归或 ARIMAX/SARIMAX 的思想。

```
1 from statsmodels.tsa.statespace.sarimax import SARIMAX
2
3 # exog_train 是外生变量, 比如价格、广告、节假日虚拟变量
4 model = SARIMAX(
5     train_y,
6     exog=exog_train,
7     order=(1,1,1),
8     seasonal_order=(1,1,1,12)
9 )
10 fit = model.fit(dispatch=False)
11 forecast = fit.forecast(steps=12, exog=exog_future)
```

10 VAR 模型与多变量时间序列

10.1 VAR 的思想

如果多个经济变量相互影响, 例如 GDP、消费、投资、利率之间可能相互作用, 单变量模型可能不够。VAR(p) 模型写为

$$\mathbf{y}_t = \mathbf{c} + A_1 \mathbf{y}_{t-1} + \cdots + A_p \mathbf{y}_{t-p} + \boldsymbol{\varepsilon}_t.$$

其中 $\mathbf{y}_t$ 是多个变量组成的向量。

10.2 适用场景

- 研究多个变量之间的动态关系;
- 分析冲击响应, 例如利率冲击对产出的影响;
- 做多变量联合预测;
- 检验某变量是否有助于预测另一个变量, 即 Granger 因果检验。

10.3 Python 示例

```
1 from statsmodels.tsa.api import VAR
2
3 # df 包含多个时间序列, 例如 GDP, CPI, rate
4 model = VAR(df)
5 fit = model.fit(maxlags=4, ic='aic')
6 forecast = fit.forecast(df.values[-fit.k_ar:], steps=4)
```


11 机器学习时间序列预测

11.1 基本思想

机器学习方法通常把时间序列预测转化为监督学习问题。例如用过去 p 期预测下一期：

$$(y_{t-1}, y_{t-2}, \dots, y_{t-p}) \longrightarrow y_t.$$

这称为构造滞后特征。

11.2 常见方法

方法	优点	注意事项
线性回归/Ridge/Lasso	简单，可解释性强	需要构造趋势、季节、滞后特征
随机森林	能处理非线性和交互	外推趋势能力弱
XGBoost/LightGBM	预测性能强，适合表格特征	需要严格按时间验证
神经网络/LSTM	可处理复杂非线性和长依赖	需要较多数据，调参复杂
Prophet/结构化模型	对趋势、节假日、季节建模方便	不适合所有数据，仍需残差诊断

11.3 滞后特征代码

```
1 def make_lag_features(y, lags=12):
2     import pandas as pd
3     df = pd.DataFrame({'y': y})
4     for k in range(1, lags + 1):
5         df[f'lag_{k}'] = df['y'].shift(k)
6     df['month'] = df.index.month
7     df = df.dropna()
8     X = df.drop(columns='y')
9     target = df['y']
10    return X, target
```

12 预测评价指标与残差诊断

12.1 常见误差指标

设真实值为 y_t ，预测值为 $\hat{y}_t$ ，误差为 $e_t = y_t - \hat{y}_t$ 。常见指标如下：

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|,$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2,$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2},$$

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|.$$

指标	优点	注意事项
MAE	单位与原变量一致，直观	对大误差惩罚不如 RMSE 强
MSE	数学性质好，常用于优化	单位是原变量平方，不够直观
RMSE	对大误差更敏感，单位直观	容易受异常点影响
MAPE	百分比误差，便于比较	当真实值接近 0 时不稳定
<i>sMAPE</i>	缓解 MAPE 的零值问题	解释不如 MAE 直观
MASE	可跨序列比较	需要基准模型作为尺度
R^2	衡量拟合解释程度	时间序列预测中不能单独作为好坏标准

scikit-learn 的 `metrics` 模块提供了多种预测误差评价函数，例如均方误差和决定系数。要注意 R^2 最好值为 1，但可能为负值，表示模型甚至不如简单均值基准。

12.2 残差诊断

模型拟合后，应检查残差：

1. 残差均值是否接近 0；
2. 残差图是否还有趋势或季节性；
3. 残差 ACF 是否显著；
4. 是否存在异常大误差；
5. 预测区间覆盖率是否合理。




图 8: 残差序列与残差分布诊断

```
1 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
2 import numpy as np
3
4 mae = mean_absolute_error(y_true, y_pred)
5 rmse = np.sqrt(mean_squared_error(y_true, y_pred))
6 mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100
7 r2 = r2_score(y_true, y_pred)
```

13 示范案例：月度销售额预测

13.1 问题描述

某地区统计了 2016 年 1 月至 2025 年 12 月的月度销售额，希望根据前 9 年数据预测最后 12 个月销售额。从图像看，该序列同时存在长期上升趋势和明显年度季节性，因此可考虑季节朴素法、Holt-Winters 模型和 SARIMA 模型进行比较。

13.2 建模假设

1. 销售额按月统计，时间间隔相等；
2. 历史趋势和季节规律在预测期内大致保持；
3. 没有发生重大结构突变；
4. 随机扰动均值接近 0；
5. 预测期外生因素保持相对稳定，或已通过模型解释。

13.3 候选模型

- 1. 季节朴素法：用上一年同月作为预测；
- 2. Holt-Winters：同时拟合水平、趋势和季节项；
- 3. SARIMA：通过一阶差分和季节差分处理非平稳性，再建立 ARMA 结构。




图 9: 训练集、测试集与三种预测结果

13.4 评价结果

表 6: 不同模型在测试集上的预测误差

模型	MAE	RMSE	MAPE	R^2
季节朴素法	10.84	11.93	5.38%	0.152
3 期均值外推	14.30	16.74	6.99%	-0.671
Holt-Winters	2.59	3.52	1.30%	0.926
SARIMA	2.28	3.19	1.15%	0.939

从结果看, SARIMA 和 Holt-Winters 都明显优于季节朴素法和均值外推法。SARIMA 的 MAE、RMSE、MAPE 略低, 说明在该示范数据上预测更准确; Holt-Winters 的解释更直观, 适合作为建模论文中的主模型或对照模型。

13.5 完整 Python 代码

```
1 import numpy as np
2 import pandas as pd
3 from statsmodels.tsa.holtwinters import ExponentialSmoothing
4 from statsmodels.tsa.statespace.sarimax import SARIMAX
5 from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
6
7 # 1. 构造或读取时间序列数据
8 # 实际建模中可用 pd.read_excel 或 pd.read_csv 读取真实数据
9 idx = pd.date_range('2016-01-01', periods=120, freq='MS')
10 np.random.seed(42)
11 t = np.arange(120)
12 trend = 100 + 0.85 * t
13 season_pattern = np.array([-14, -10, -6, 2, 8, 12, 18, 16, 7, 1, -6, -12])
14 season = np.tile(season_pattern, 10)
15 noise = np.random.normal(0, 4, 120)
16 y = pd.Series(trend + season + noise, index=idx, name='sales')
17
18 # 2. 按时间顺序划分训练集和测试集
19 train = y.iloc[:-12]
20 test = y.iloc[-12:]
21
22 # 3. 季节朴素法
23 seasonal_naive = pd.Series(train.iloc[-12:].values, index=test.index)
24
25 # 4. Holt-Winters 模型
26 hw_model = ExponentialSmoothing(
27     train,
28     trend='add',
29     seasonal='add',
30     seasonal_periods=12
31 )
32 hw_fit = hw_model.fit(optimized=True)
33 hw_pred = hw_fit.forecast(12)
34
35 # 5. SARIMA 模型
36 sarima_model = SARIMAX(
37     train,
38     order=(1, 1, 1),
39     seasonal_order=(1, 1, 1, 12),
40     enforce_stationarity=False,
41     enforce_invertibility=False
42 )
43 sarima_fit = sarima_model.fit(dispatch=False)
44 sarima_pred = sarima_fit.forecast(12)
45
```

```
46 # 6. 误差评价函数
47 def evaluate(y_true, y_pred):
48     mae = mean_absolute_error(y_true, y_pred)
49     rmse = np.sqrt(mean_squared_error(y_true, y_pred))
50     mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100
51     r2 = r2_score(y_true, y_pred)
52     return mae, rmse, mape, r2
53
54 for name, pred in {
55     'seasonal_naive': seasonal_naive,
56     'holt_winters': hw_pred,
57     'sarima': sarima_pred
58 }.items():
59     print(name, evaluate(test, pred))
```

13.6 规范论文写法示例

在论文或建模报告中，可以这样写：

本文选取某地区月度销售额作为研究对象。首先绘制时间序列图，发现序列具有明显上升趋势和年度季节性。为保证预测评价的客观性，将前 108 个月作为训练集，最后 12 个月作为测试集。候选模型包括季节朴素法、Holt-Winters 指数平滑模型和 SARIMA 模型。模型参数通过训练集估计，预测效果使用 MAE、RMSE、MAPE 和 R^2 评价。结果表明，SARIMA 模型在测试集上误差最小，说明其更适合描述该序列的趋势、季节和自相关结构。

14 不同方法的选择建议

数据特征	推荐方法	建模说明
无趋势无季节	平均法、一次指数平滑、ARMA	先检查平稳性，再看残差自相关
有趋势无季节	趋势回归、Holt、ARIMA	可用差分或显式趋势项处理
有季节无趋势	季节朴素法、季节分解、SARIMA	月度数据常用周期 12
有趋势有季节	Holt-Winters、SARIMA、动态回归	建议至少比较两个模型
多个变量相互影响	VAR、VECM、动态回归	适合经济系统联动分析
有外生影响因素	ARIMAX/SARIMAX、回归 + ARMA 误差	需提供未来外生变量或情景假设

非线性强、数据量大 随机森林、XGBoost、特征构造和时间验证非常重要
LSTM

15 常见错误与注意事项

1. **随机打乱数据**：时间序列预测不能随机划分训练测试集。
2. **只看拟合不看预测**：训练集拟合好不代表未来预测好。
3. **只看 R^2** ：预测问题更应关注 MAE、RMSE、MAPE 和残差诊断。
4. **忽略季节性**：月度和季度经济数据往往有季节效应。
5. **过度差分**：差分过多会丢失有效信息。
6. **盲目套模型**：ARIMA、LSTM 等都不是万能模型，必须结合数据特征和业务背景。
7. **没有基准模型**：至少应与平均法、朴素法或季节朴素法比较。

16 总结

时间序列建模的核心是：先看图，再分析结构，最后选择模型。一般流程为：

数据整理 → 图形探索 → 平稳性分析 → 模型拟合 → 预测评价 → 结论解释。

基础方法包括平均法、朴素法、移动平均和指数平滑；统计模型包括 AR、MA、ARMA、ARIMA、SARIMA 和 VAR；现代方法包括机器学习、深度学习和混合模型。对于数学建模竞赛和课程论文，最重要的不是堆砌复杂模型，而是把“为什么选这个模型、公式中每一项表示什么、参数如何估计、预测效果如何评价”写清楚。

参考资料

1. Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*, 3rd edition. OTexts. <https://otexts.com/fpp3/>
2. statsmodels documentation. Time Series analysis `tsa`. <https://www.statsmodels.org/stable/tsa.html>
3. statsmodels documentation. `statsmodels.tsa.arima.model.ARIMA`. <https://www.statsmodels.org/stable/generated/statsmodels.tsa.arima.model.ARIMA.html>
4. statsmodels documentation. `statsmodels.tsa.holtwinters.ExponentialSmoothing`. <https://www.statsmodels.org/devel/generated/statsmodels.tsa.holtwinters.ExponentialSmoothing.html>
5. scikit-learn documentation. Metrics and scoring: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html
6. scikit-learn documentation. `mean_squared_error` and `r2_score`. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html